Master 1 MIASHS — TP statistique inférentielle

Étude des estimateurs des moments et du maximum de vraissemblance

Manal Amhal

Table des matières

1 Méthode des moments **2**

1.1 Loi de Bernoulli $\mathcal{B}(p)$, $p \in]0,1[$ 2

1.2 Loi binomiale $\mathcal{B}(k,p)$, $k \in \mathbb{N}^*$, $p \in]0,1[$ 2

1.3 Loi de Poisson $\mathcal{P}(\lambda)$, $\lambda > 0$ 3

1.4 Loi géométrique $\mathcal{G}(p)$, $p \in]0,1[$ 4

1.5 Loi uniforme discrète $\mathcal{U}(1,m)$ 4

1.6 Loi binomiale négative $\mathcal{BN}(r,p)$, $r \in \mathbb{N}^*$, $p \in]0,1[$ 5

1.7 Loi exponentielle $\mathcal{E}(\lambda)$, $\lambda > 0$ 5

1.8 Loi normale $\mathcal{N}(\mu,\sigma^2)$ 6

1.9 Loi uniforme continue $\mathcal{U}([a,b])$ 6

1.10 Loi gamma $\Gamma(a,b)$, $a > 0$, $b > 0$ 8

1.11 Loi bêta $\mathcal{B}(a,b)$, $a > 0$, $b > 0$ 9

2 Maximum de vraisemblance **11**

2.1 Loi de Bernoulli $\mathcal{B}(p)$, $p \in]0,1[$ 11

2.2 Loi binomiale $\mathcal{B}(k,p)$ 11

2.3 Loi géométrique $\mathcal{G}(p)$ 12

2.4 Loi de Poisson $\mathcal{P}(\lambda)$ 12

2.5 Loi uniforme discrète 13

2.6 Loi binomiale négative $\mathcal{BN}(r,p)$ 13

2.7 Loi exponentielle $\mathcal{E}(\lambda)$ 14

2.8 Loi normale $\mathcal{N}(\mu,\sigma^2)$ 14

2.9 Loi uniforme continue $\mathcal{U}([a,b])$ 15

3 Récapitulatif **16**

Conventions. Dans tout le document, $X = (X_1, \ldots, X_n)$ désigne un n-échantillon (i.i.d.), $\overline{x}_n = \frac{1}{n}\sum_{i=1}^n x_i$ la moyenne empirique et $S_n^2 = \frac{1}{n}\sum_{i=1}^n x_i^2 - \overline{x}_n^2 = \frac{1}{n}\sum_{i=1}^n (x_i - \overline{x}_n)^2$ la variance empirique. Pour éviter toute confusion avec la taille n de l'échantillon, les paramètres « de taille » des lois (binomiale, binomiale négative, uniforme discrète) sont notés k, r et m.

1 Méthode des moments

Définition

Soit X un n-échantillon de $\mathbb{R}^d$. Soit q fonctions $\varphi_j : \mathbb{R}^d \to \mathbb{R}^{n_j}$, $\forall j \in 1,q$, telles que $\mathbb{E}_\theta(\|\varphi_j(X_1)\|) < \infty$, et $\psi : \prod_j \mathbb{R}^{n_j} \to \mathbb{R}^m$. On pose

$$g(\theta^*) = \psi(\mathbb{E}_{\theta^*}(\varphi_1(X_1)), \dots, \mathbb{E}_{\theta^*}(\varphi_q(X_1))), \qquad \widehat{g}_n = \psi\Big(\frac{1}{n}\sum_{i=1}^n \varphi_1(X_i), \dots, \frac{1}{n}\sum_{i=1}^n \varphi_q(X_i)\Big).$$

D'après la loi forte des grands nombres, $\widehat{g}_n \xrightarrow[n\to\infty]{\text{p.s.}} g(\theta^*)$.

But : on estime une quantité théorique dépendant d'un paramètre en la remplaçant par son équivalent empirique.

Méthode en trois étapes.

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

(2) On inverse le système d'équations.

(3) On remplace par les moments empiriques.

1.1 Loi de Bernoulli $\mathcal{B}(p)$, $p \in]0,1[$

Soit X un n-échantillon.

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$$\mathbb{E}(X_1) = \sum_{x\in\{0,1\}} x\,\mathbb{P}(X=x) = p, \qquad \mathbb{E}(X_1^2) = \sum_{x\in\{0,1\}} x^2\,\mathbb{P}(X=x) = p,$$
$$\mathbb{V}(X_1) = \mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2 = p - p^2 = p(1-p).$$

(2) On inverse le système d'équations.

$$p = \mathbb{E}(X_1) \qquad \text{et} \qquad p(1-p) = \mathbb{V}(X_1).$$

(3) On remplace par les moments empiriques.

$$\widehat{p}_n = \frac{1}{n}\sum_{i=1}^n x_i = \overline{x}_n \qquad \text{et} \qquad \widehat{\sigma}_n^2 = \overline{x}_n\,(1-\overline{x}_n).$$

1.2 Loi binomiale $\mathcal{B}(k,p)$, $k \in \mathbb{N}^*$, $p \in]0,1[$

Soit X un n-échantillon.

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$$\mathbb{E}(X_1) = \sum_{x=0}^{k} x\,\mathbb{P}(X=x) = \sum_{x=0}^{k} x\binom{k}{x}p^x(1-p)^{k-x} = \sum_{x=1}^{k} x\,\frac{k!}{x!\,(k-x)!}\,p^x(1-p)^{k-x}$$
$$= kp\sum_{x=1}^{k}\frac{(k-1)!}{(x-1)!\,(k-x)!}\,p^{x-1}(1-p)^{k-x} \overset{j=x-1}{=} kp\sum_{j=0}^{k-1}\binom{k-1}{j}p^j(1-p)^{k-1-j} = kp.$$

On a $\mathbb{E}(X_1^2) = \mathbb{E}\big(X_1(X_1-1+1)\big) = \mathbb{E}\big(X_1(X_1-1)\big) + \mathbb{E}(X_1) = \mathbb{E}\big(X_1(X_1-1)\big) + kp$, avec

$$\mathbb{E}\big(X_1(X_1-1)\big) = \sum_{x=2}^{k} x(x-1)\binom{k}{x}p^x(1-p)^{k-x} = p^2k(k-1)\sum_{j=0}^{k-2}\frac{(k-2)!}{j!\,(k-2-j)!}\,p^j(1-p)^{k-2-j} \quad (j=x-2)$$
$$= p^2k(k-1)\sum_{j=0}^{k-2}\binom{k-2}{j}p^j(1-p)^{k-2-j} = p^2k(k-1).$$

Donc $\mathbb{E}(X_1^2) = k^2p^2 - kp^2 + kp$ et

$$\mathbb{V}(X_1) = \mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2 = k^2p^2 - kp^2 + kp - k^2p^2 = kp(1-p).$$

(2) On inverse le système d'équations.

$$p = \frac{\mathbb{E}(X_1)}{k}, \qquad p(1-p)k = \mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2.$$

(3) On remplace par les moments empiriques.

$$\widehat{p}_n = \frac{\overline{x}_n}{k} \qquad \text{et} \qquad \widehat{\sigma}_n^2 = k\,\widehat{p}_n\,(1-\widehat{p}_n) = \overline{x}_n\Big(1-\frac{\overline{x}_n}{k}\Big).$$

1.3 Loi de Poisson $\mathcal{P}(\lambda)$, $\lambda > 0$

Soit X un n-échantillon.

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$$\mathbb{E}(X_1) = \sum_{x=0}^{\infty} x\,e^{-\lambda}\frac{\lambda^x}{x!} = e^{-\lambda}\sum_{x=1}^{\infty}\frac{\lambda^x}{(x-1)!} = e^{-\lambda}\lambda\sum_{x=1}^{\infty}\frac{\lambda^{x-1}}{(x-1)!} = \lambda.$$

On a $\mathbb{E}(X_1^2) = \mathbb{E}\big(X_1(X_1-1)\big) + \mathbb{E}(X_1)$ et

$$\mathbb{E}\big(X_1(X_1-1)\big) = \sum_{x=2}^{\infty} x(x-1)e^{-\lambda}\frac{\lambda^x}{x!} = e^{-\lambda}\lambda^2\sum_{x=2}^{\infty}\frac{\lambda^{x-2}}{(x-2)!} = \lambda^2.$$

D'où $\mathbb{E}(X_1^2) = \lambda^2 + \lambda = \lambda(1+\lambda)$ et $\mathbb{V}(X_1) = \mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2 = \lambda$.

(2) On inverse le système d'équations.

$$\lambda = \mathbb{E}(X_1).$$

(3) On remplace par les moments empiriques.

$$\widehat{\lambda}_n = \overline{x}_n \qquad \text{et} \qquad \widehat{\sigma}_n^2 = \widehat{\lambda}_n = \overline{x}_n.$$

1.4 Loi géométrique $\mathcal{G}(p)$, $p \in]0,1[$

Soit X un n-échantillon, avec $\mathbb{P}(X = x) = p(1-p)^{x-1}$ pour $x \in \mathbb{N}^*$.

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

Avec $q = 1 - p$:

$$\mathbb{E}(X_1) = \sum_{x=1}^{\infty} x\, p\, (1-p)^{x-1} = p \sum_{x=1}^{\infty} x\, q^{x-1}.$$

Par série entière et dérivation, on a $\displaystyle\sum_{x=0}^{\infty} q^x = \frac{1}{1-q}$, donc

$$\frac{d}{dq}\Big(\sum_{x=0}^{\infty} q^x\Big) = \frac{d}{dq}\Big(\frac{1}{1-q}\Big) \iff \sum_{x=1}^{\infty} x\, q^{x-1} = \frac{1}{(1-q)^2}, \qquad \text{d'où} \qquad \mathbb{E}(X_1) = p \cdot \frac{1}{(1-q)^2} = \frac{p}{p^2} = \frac{1}{p}.$$

Pour le moment d'ordre 2 : $\mathbb{E}(X_1^2) = \mathbb{E}\big(X_1(X_1-1)\big) + \mathbb{E}(X_1)$ et

$$\mathbb{E}\big(X_1(X_1-1)\big) = \sum_{x=2}^{\infty} x(x-1)\, p\, q^{x-1} = pq \sum_{x=2}^{\infty} x(x-1)\, q^{x-2}.$$

En dérivant à nouveau : $\displaystyle\frac{d}{dq}\Big(\sum x\, q^{x-1}\Big) = \frac{d}{dq}\Big(\frac{1}{(1-q)^2}\Big)$, soit $\displaystyle\sum_{x\geq 2} x(x-1)q^{x-2} = \frac{2(1-q)}{(1-q)^4} = \frac{2}{p^3}$.

Ainsi

$$\mathbb{E}(X_1(X_1-1)) = \frac{2p(1-p)}{p^3} = \frac{2(1-p)}{p^2}, \qquad \mathbb{E}(X_1^2) = \frac{2(1-p)}{p^2} + \frac{1}{p} = \frac{2-p}{p^2},$$

$$\mathbb{V}(X_1) = \mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2 = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}.$$

(2) On inverse le système d'équations.

$$p = \frac{1}{\mathbb{E}(X_1)}.$$

(3) On remplace par les moments empiriques.

$$\widehat{p}_n = \frac{1}{\overline{x}_n} = \frac{n}{\sum_{i=1}^n x_i} \qquad \text{et} \qquad \widehat{\sigma}_n^2 = \frac{1-\widehat{p}_n}{\widehat{p}_n^2} = \frac{1-\frac{1}{\overline{x}_n}}{\overline{x}_n^{-2}}.$$

1.5 Loi uniforme discrète $\mathcal{U}(1,m)$

Soit X un n-échantillon, $\mathbb{P}(X = x) = \frac{1}{m}$ pour $x \in 1, m$. On rappelle

$$\sum_{x=1}^{m} x = \frac{m(m+1)}{2}, \qquad \sum_{x=1}^{m} x^2 = \frac{m(m+1)(2m+1)}{6}.$$

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$$\mathbb{E}(X) = \frac{1}{m}\sum_{x=1}^{m} x = \frac{m+1}{2}, \qquad \mathbb{E}(X^2) = \frac{1}{m}\sum_{x=1}^{m} x^2 = \frac{(m+1)(2m+1)}{6},$$

$$\mathbb{V}(X) = \frac{(m+1)(2m+1)}{6} - \Big(\frac{m+1}{2}\Big)^2 = \frac{m+1}{2}\Big(\frac{2m+1}{3} - \frac{m+1}{2}\Big) = \frac{m+1}{2}\cdot\frac{m-1}{6} = \frac{m^2-1}{12}.$$

(2) On inverse le système d'équations.

$$\mathbb{E}(X) = \frac{m+1}{2} \iff 2\mathbb{E}(X) - 1 = m.$$

(3) On remplace par les moments empiriques.

$$\widehat{m}_n = 2\overline{x}_n - 1 \qquad \text{et} \qquad \widehat{\sigma}_n^2 = \frac{(2\overline{x}_n - 1)^2 - 1}{12}.$$

1.6 Loi binomiale négative $\mathcal{BN}(r,p)$, $r \in \mathbb{N}^*$, $p \in]0,1[$

Ici r est le nombre de succès visés et p la probabilité de succès à chaque tirage, et

$$\mathbb{P}(X = x) = \binom{x+r-1}{x} p^r (1-p)^x, \qquad x \in \mathbb{N}.$$

Si $X_1, \dots, X_r$ sont indépendantes de loi $\mathcal{G}(p)$ (version à valeurs dans $\mathbb{N}$: nombre d'échecs avant le premier succès, d'espérance $\frac{1-p}{p}$ et de variance $\frac{1-p}{p^2}$), alors $\sum_{i=1}^r X_i \sim \mathcal{BN}(r,p)$.

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$$\mathbb{E}\Big(\sum_{i=1}^r X_i\Big) = \sum_{i=1}^r \mathbb{E}(X_i) = \frac{r(1-p)}{p}, \qquad \mathbb{V}\Big(\sum_{i=1}^r X_i\Big) = \sum_{i=1}^r \mathbb{V}(X_i) = \frac{r(1-p)}{p^2}.$$

(2) On inverse le système d'équations.

$$\mathbb{E}(X) = \frac{r(1-p)}{p} \iff p\,\mathbb{E}(X) = r - rp \iff p\,(\mathbb{E}(X) + r) = r \iff p = \frac{r}{\mathbb{E}(X) + r}.$$

(3) On remplace par les moments empiriques.

$$\widehat{p}_n = \frac{r}{\overline{x}_n + r} \qquad \text{et} \qquad \widehat{\sigma}_n^2 = \frac{r(1-\widehat{p}_n)}{\widehat{p}_n^2}.$$

1.7 Loi exponentielle $\mathcal{E}(\lambda)$, $\lambda > 0$

Densité $f_\lambda(x) = \lambda e^{-\lambda x} \mathbf{1}_{\mathbb{R}_+}(x)$.

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

Par intégration par parties ($u(x) = x$, $v'(x) = \lambda e^{-\lambda x}$) :

$$\mathbb{E}(X_1) = \int_0^\infty x\,\lambda e^{-\lambda x}\,dx = \Big[-xe^{-\lambda x}\Big]_0^\infty + \int_0^\infty e^{-\lambda x}\,dx = \Big[-\frac{1}{\lambda}e^{-\lambda x}\Big]_0^\infty = \frac{1}{\lambda}.$$

Pour $\mathbb{E}(X_1^2)$ ($u(x) = x^2$, $v'(x) = \lambda e^{-\lambda x}$) :

$$\mathbb{E}(X_1^2) = \Big[-x^2 e^{-\lambda x} \Big]_0^\infty + 2\int_0^\infty x\, e^{-\lambda x}\, dx = \frac{2}{\lambda}\int_0^\infty x\, \lambda e^{-\lambda x}\, dx = \frac{2}{\lambda}\,\mathbb{E}(X_1) = \frac{2}{\lambda^2}.$$

D'où $\mathbb{V}(X_1) = \mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2 = \dfrac{2}{\lambda^2} - \dfrac{1}{\lambda^2} = \dfrac{1}{\lambda^2}$.

(2) On inverse le système d'équations.

On a $\mathbb{E}(X_1) = \frac{1}{\lambda}$ et $\mathbb{V}(X_1) = \frac{1}{\lambda^2}$, d'où $\lambda = \dfrac{1}{\mathbb{E}(X_1)}$.

(3) On remplace par les moments empiriques.

Par la loi forte des grands nombres, $\overline{x}_n \xrightarrow{\text{p.s.}} \mathbb{E}(X_1)$, d'où

$$\widehat{\lambda}_n = \frac{1}{\overline{x}_n}.$$

(De même $\frac{1}{n}\sum x_i^2 \to \frac{2}{\lambda^2}$, ce qui donnerait un second estimateur $\sqrt{2/\overline{x^2}}$.)

1.8 Loi normale $\mathcal{N}(\mu, \sigma^2)$

Soit X un n-échantillon de loi $\mathcal{N}(\mu, \sigma^2)$.

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

Par définition, $\mathbb{E}(X_1) = \mu$ et $\mathbb{V}(X_1) = \sigma^2$.

(2) On inverse le système d'équations.

$\mu = \mathbb{E}(X_1)$ et $\sigma^2 = \mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2$.

(3) On remplace par les moments empiriques.

Comme $\overline{x}_n \xrightarrow[n\to\infty]{\text{p.s.}} \mathbb{E}(X_1) = \mu$, $\frac{1}{n}\sum x_i^2 \xrightarrow[n\to\infty]{\text{p.s.}} \mathbb{E}(X_1^2)$ et $\left(\frac{1}{n}\sum x_i\right)^2 \xrightarrow[n\to\infty]{\text{p.s.}} \mathbb{E}(X_1)^2$:

$$\widehat{\mu}_n = \overline{x}_n \qquad \text{et} \qquad \widehat{\sigma}_n^2 = \frac{1}{n}\sum_{i=1}^n x_i^2 - \overline{x}_n^2 = S_n^2.$$

1.9 Loi uniforme continue $\mathcal{U}([a, b])$

Densité $f_X(x) = \dfrac{1}{b-a}\mathbf{1}_{[a,b]}(x)$.

Cas 1 : $\mathcal{U}([0, b])$ avec $b > 0$

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$$\mathbb{E}(X_1) = \int_0^b \frac{x}{b}\, dx = \frac{1}{b}\Big[\frac{x^2}{2}\Big]_0^b = \frac{b}{2}.$$

(2) On inverse le système d'équations.

$\mathbb{E}(X_1) = \frac{b}{2}$ d'où $b = 2\mathbb{E}(X_1)$.

(3) On remplace par les moments empiriques.

$$\widehat{b}_n = 2\overline{x}_n.$$

Cas 2 : $\mathcal{U}([a,b])$ avec $a < b$

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$$\mathbb{E}(X_1) = \int_a^b \frac{x}{b-a}\,dx = \frac{1}{b-a}\Big[\frac{x^2}{2}\Big]_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{a+b}{2}, \qquad \mathbb{E}(X_1^2) = \frac{1}{b-a}\Big[\frac{x^3}{3}\Big]_a^b = \frac{b^3-a^3}{3(b-a)}.$$

On utilise $b^3 - a^3 = (b-a)(a^2+ab+b^2)$ et $b^2 - a^2 = (b-a)(b+a)$, d'où $\mathbb{E}(X_1^2) = \dfrac{a^2+ab+b^2}{3}$ et

$$\mathbb{V}(X_1) = \frac{a^2+ab+b^2}{3} - \frac{(a+b)^2}{4} = \frac{4(a^2+ab+b^2) - 3(a^2+2ab+b^2)}{12} = \frac{a^2-2ab+b^2}{12} = \frac{(b-a)^2}{12}.$$

(2) On inverse le système d'équations.

$$\begin{cases} \mathbb{E}(X_1) = \frac{a+b}{2} \\ \mathbb{V}(X_1) = \frac{(b-a)^2}{12} \end{cases} \iff \begin{cases} 2\mathbb{E}(X_1) = a+b \\ 12\,\mathbb{V}(X_1) = (b-a)^2 \end{cases} \iff \begin{cases} 2\mathbb{E}(X_1) = a+b \\ 2\sqrt{3}\sqrt{\mathbb{V}(X_1)} = b-a \end{cases}$$

(avec $b > a$), d'où $b = \mathbb{E}(X_1) + \sqrt{3}\sqrt{\mathbb{V}(X_1)}$ et $a = \mathbb{E}(X_1) - \sqrt{3}\sqrt{\mathbb{V}(X_1)}$.

(3) On remplace par les moments empiriques.

On a $\overline{x}_n \to \mathbb{E}(X_1)$ et $S_n^2 \to \mathbb{V}(X_1)$:

$$\widehat{b}_n = \overline{x}_n + \sqrt{3}\,\sqrt{S_n^2} = \overline{x}_n + \sqrt{3}\,S_n \qquad \text{et} \qquad \widehat{a}_n = \overline{x}_n - \sqrt{3}\,S_n.$$

Cas 3 : $\mathcal{U}([a,0])$ avec $a < 0$

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$$\mathbb{E}(X_1) = \int_a^0 \frac{x}{0-a}\,dx = \frac{1}{-a}\Big[\frac{x^2}{2}\Big]_a^0 = \frac{a}{2}.$$

(2) On inverse le système d'équations.

$2\mathbb{E}(X_1) = a$.

(3) On remplace par les moments empiriques.

$$\widehat{a}_n = 2\overline{x}_n.$$

1.10 Loi gamma $\Gamma(a,b)$, $a>0$, $b>0$

Densité $f(x)=\dfrac{b^a}{\Gamma(a)}x^{a-1}e^{-bx}\mathbf{1}_{\mathbb{R}_+}(x)$. On rappelle que $\Gamma(1,b)=\mathcal{E}(b)$ et

$$\mathbb{E}(X_1)=\frac{a}{b},\qquad \mathbb{V}(X_1)=\frac{a}{b^2}.$$

Cas 1 : estimation de b avec a connu

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$\mathbb{E}(X_1)=\dfrac{a}{b}$.

(2) On inverse le système d'équations.

$\dfrac{a}{\mathbb{E}(X_1)}=b$.

(3) On remplace par les moments empiriques.

$$\widehat{b}_n=\frac{a}{\overline{x}_n}.$$

Cas 2 : estimation de a et b

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$\mathbb{E}(X_1)=\dfrac{a}{b}$ et $\mathbb{V}(X_1)=\dfrac{a}{b^2}$.

(2) On inverse le système d'équations.

$$\frac{\mathbb{E}(X_1)^2}{\mathbb{V}(X_1)}=\frac{a^2/b^2}{a/b^2}=a,\qquad \frac{\mathbb{E}(X_1)}{a}=\frac{1}{b}\implies b=\frac{a}{\mathbb{E}(X_1)}=\frac{\mathbb{E}(X_1)}{\mathbb{V}(X_1)}.$$

$$\boxed{a=\frac{\mathbb{E}(X_1)^2}{\mathbb{V}(X_1)},\qquad b=\frac{\mathbb{E}(X_1)}{\mathbb{V}(X_1)}}$$

(3) On remplace par les moments empiriques.

$$\widehat{a}_n=\frac{\overline{x}_n^2}{S_n^2}\qquad\text{et}\qquad \widehat{b}_n=\frac{\overline{x}_n}{S_n^2}.$$

Cas 3 : estimation de a avec b connu

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$\mathbb{E}(X_1)=\dfrac{a}{b}$.

(2) On inverse le système d'équations.

$b\,\mathbb{E}(X_1) = a.$

(3) On remplace par les moments empiriques.

$$\widehat{a}_n = b\,\overline{x}_n.$$

1.11 Loi bêta $\mathcal{B}(a,b)$, $a>0$, $b>0$

Densité $f(x) = \dfrac{1}{B(a,b)} x^{a-1}(1-x)^{b-1}\mathbf{1}_{[0,1]}(x)$, avec

$$\mathbb{E}(X_1) = \frac{a}{a+b}, \qquad \mathbb{V}(X_1) = \frac{ab}{(a+b)^2(a+b+1)}.$$

Cas 1 : estimation de b (a connu)

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$\mathbb{E}(X_1) = \dfrac{a}{a+b}.$

(2) On inverse le système d'équations.

$$\frac{\mathbb{E}(X_1)}{a} = \frac{1}{a+b} \implies \frac{a}{\mathbb{E}(X_1)} = a+b \implies b = \frac{a}{\mathbb{E}(X_1)} - a = a\Big(\frac{1}{\mathbb{E}(X_1)} - 1\Big).$$

(3) On remplace par les moments empiriques.

$$\widehat{b}_n = a\Big(\frac{1}{\overline{x}_n} - 1\Big).$$

Cas 2 : estimation de a (b connu)

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

$\mathbb{E}(X_1) = \dfrac{a}{a+b}.$

(2) On inverse le système d'équations.

$$(a+b)\,\mathbb{E}(X_1) = a \implies b\,\mathbb{E}(X_1) = a\big(1-\mathbb{E}(X_1)\big) \implies a = \frac{b\,\mathbb{E}(X_1)}{1-\mathbb{E}(X_1)}.$$

(3) On remplace par les moments empiriques.

$$\widehat{a}_n = \frac{b\,\overline{x}_n}{1-\overline{x}_n}.$$

Cas 3 : a et b inconnus

(1) On exprime le paramètre d'intérêt en fonction des moments théoriques.

On pose $s = a + b$. Alors $\mathbb{E}(X_1) = \dfrac{a}{s}$, soit $a = s\,\mathbb{E}(X_1)$. Puis

$$\mathbb{E}(X_1) = \frac{s\,\mathbb{E}(X_1)}{s\,\mathbb{E}(X_1) + b} \implies s = s\,\mathbb{E}(X_1) + b \implies b = s\big(1 - \mathbb{E}(X_1)\big).$$

Comme $\mathbb{V}(X_1) = \dfrac{ab}{(a+b)^2(a+b+1)}$ on a

$$\mathbb{V}(X_1) = \frac{s^2\,\mathbb{E}(X_1)\big(1 - \mathbb{E}(X_1)\big)}{s^2(s+1)} = \frac{\mathbb{E}(X_1)\big(1 - \mathbb{E}(X_1)\big)}{s+1}.$$

(2) On inverse le système d'équations.

$$s + 1 = \frac{\mathbb{E}(X_1)(1 - \mathbb{E}(X_1))}{\mathbb{V}(X_1)} \implies s = \frac{\mathbb{E}(X_1)(1 - \mathbb{E}(X_1))}{\mathbb{V}(X_1)} - 1,$$

$$a = \mathbb{E}(X_1)\Big(\frac{\mathbb{E}(X_1)(1 - \mathbb{E}(X_1))}{\mathbb{V}(X_1)} - 1\Big), \qquad b = \big(1 - \mathbb{E}(X_1)\big)\Big(\frac{\mathbb{E}(X_1)(1 - \mathbb{E}(X_1))}{\mathbb{V}(X_1)} - 1\Big).$$

(3) On remplace par les moments empiriques.

$$\widehat{a}_n = \overline{x}_n\Big(\frac{\overline{x}_n(1 - \overline{x}_n)}{S_n^2} - 1\Big), \qquad \widehat{b}_n = (1 - \overline{x}_n)\Big(\frac{\overline{x}_n(1 - \overline{x}_n)}{S_n^2} - 1\Big).$$

2 Maximum de vraisemblance

Définition

Étant donné un n-échantillon de densité f_{θ^*}, la méthode du maximum de vraisemblance consiste à estimer $g(\theta^*) = \theta^*$ par le $\theta \in \Theta$ qui maximise $V_X(\theta)$, où $V_X(\theta) = \prod_{i=1}^n f_\theta(x_i)$ est la vraisemblance.

Méthode. On écrit la vraisemblance, on passe à la log-vraisemblance $\ln V_X(\theta)$, puis :

(1) Équation $\partial_\theta \ln V_X(\theta) = 0$.

(2) Vérification de la concavité.

Lorsque le support dépend du paramètre (lois uniformes), on étudie directement les variations de V_X sans dériver.

2.1 Loi de Bernoulli $\mathcal{B}(p)$, $p \in]0,1[$

On a $\mathbb{P}(X = x) = p^x(1-p)^{1-x}$ et $(\theta = p)$

$$V_X(p) = \prod_{i=1}^n p^{x_i}(1-p)^{1-x_i} = p^{\sum x_i}(1-p)^{n-\sum x_i}.$$

On passe à la log-vraisemblance : $\ln V_X(p) = \sum x_i \ln p + (n - \sum x_i)\ln(1-p)$.

(1) Équation $\partial_\theta \ln V_X(\theta) = 0$.

$$\frac{\partial}{\partial p}\ln V_X(p) = 0 \iff \frac{\sum x_i}{p} - \frac{n-\sum x_i}{1-p} = 0 \iff (1-p)\sum x_i - p\Big(n - \sum x_i\Big) = 0 \iff \sum x_i - pn = 0 \iff p =$$

(2) Vérification de la concavité.

$$\frac{\partial^2}{\partial p^2}\ln V_X(p) = -\frac{\sum x_i}{p^2} - \frac{n-\sum x_i}{(1-p)^2} < 0.$$

$$\widehat{p}_n = \overline{x}_n = \frac{1}{n}\sum_{i=1}^n x_i.$$

2.2 Loi binomiale $\mathcal{B}(k,p)$

On a $\mathbb{P}(X = x) = \binom{k}{x} p^x(1-p)^{k-x}$ et

$$V_X(p) = \prod_{i=1}^n \binom{k}{x_i} p^{x_i}(1-p)^{k-x_i} = \prod_{i=1}^n \binom{k}{x_i}\, p^{\sum x_i}(1-p)^{kn-\sum x_i}.$$

$$\ln V_X(p) = \sum x_i \ln p + \Big(nk - \sum x_i\Big)\ln(1-p) + \sum_{i=1}^n \ln \binom{k}{x_i}.$$

(1) Équation $\partial_\theta \ln V_X(\theta) = 0$.

$$\frac{\partial}{\partial p}\ln V_X(p) = \frac{\sum x_i}{p} - \frac{nk - \sum x_i}{1-p} = 0 \iff \sum x_i(1-p) - p\Big(nk - \sum x_i\Big) = 0 \iff \frac{1}{n}\sum x_i = pk \iff \frac{1}{k}\Big(\frac{1}{n}\sum x_i$$

(2) Vérification de la concavité.

$$\frac{\partial^2}{\partial p^2}\ln V_X(p) = -\frac{\sum x_i}{p^2} - \frac{nk - \sum x_i}{(1-p)^2} < 0.$$

$$\widehat{p}_n = \frac{\overline{x}_n}{k}.$$

2.3 Loi géométrique $\mathcal{G}(p)$

On a $\mathbb{P}(X = x) = p(1-p)^{x-1}$, $x \in \mathbb{N}^*$, donc

$$V_X(p) = \prod_{i=1}^{n} p(1-p)^{x_i - 1} = p^n (1-p)^{\sum x_i - n}.$$

$$\ln V_X(p) = n \ln p + \Big(\sum x_i - n\Big)\ln(1-p).$$

(1) Équation $\partial_\theta \ln V_X(\theta) = 0$.

$$\frac{\partial}{\partial p}\ln V_X(p) = \frac{n}{p} - \frac{\sum x_i - n}{1-p} = 0 \iff \frac{n(1-p) - p(\sum x_i - n)}{p(1-p)} = 0 \iff n - p\sum x_i = 0 \iff \frac{1}{n}\sum x_i = \frac{1}{p}.$$

(2) Vérification de la concavité.

$$\frac{\partial^2}{\partial p^2}\ln V_X(p) = -\frac{n}{p^2} - \frac{\sum x_i - n}{(1-p)^2} < 0.$$

$$\widehat{p}_n = \frac{1}{\overline{x}_n}.$$

2.4 Loi de Poisson $\mathcal{P}(\lambda)$

On a $\mathbb{P}(X = x) = e^{-\lambda}\dfrac{\lambda^x}{x!}$ et

$$V_X(\lambda) = \prod_{i=1}^{n} e^{-\lambda}\frac{\lambda^{x_i}}{x_i!} = e^{-\lambda n}\lambda^{\sum x_i}\prod_{i=1}^{n}\frac{1}{x_i!}.$$

$$\ln V_X(\lambda) = -\lambda n + \sum x_i \ln\lambda + \ln\Big(\prod_{i=1}^{n}\frac{1}{x_i!}\Big).$$

(1) Équation $\partial_\theta \ln V_X(\theta) = 0$.

$$\frac{\partial}{\partial\lambda} \ln V_X(\lambda) = -n + \frac{\sum x_i}{\lambda} = 0 \iff \sum x_i = \lambda n \iff \lambda = \frac{\sum x_i}{n}.$$

(2) Vérification de la concavité.

$$\frac{\partial^2}{\partial\lambda^2} \ln V_X(\lambda) = -\frac{\sum x_i}{\lambda^2} < 0.$$

$$\widehat{\lambda}_n = \overline{x}_n.$$

2.5 Loi uniforme discrète

Cas 1 : $\mathcal{U}(1,\theta)$, $\theta \in \mathbb{N}^*$

$$\mathbb{P}(X = x) = \frac{1}{\theta}\mathbf{1}_{1,\theta}(x), \quad x \in \mathbb{N}^*,$$

c'est-à-dire $\mathbb{P}(X = x) = \frac{1}{\theta}$ si $1 \leq x \leq \theta$. La vraisemblance est

$$V_X(\theta) = \prod_{i=1}^n \frac{1}{\theta}\mathbf{1}_{1,\theta}(x_i) = \frac{1}{\theta^n}\prod_{i=1}^n \mathbf{1}_{1,\theta}(x_i) = \begin{cases} \dfrac{1}{\theta^n} & \text{si } \max_i x_i \leq \theta, \\ 0 & \text{sinon.} \end{cases}$$

En effet $\prod_i \mathbf{1}_{1,\theta}(x_i) = 1 \iff \forall i,\ 1 \leq x_i \leq \theta \iff \max_{1\leq i\leq n} x_i \leq \theta$. Comme $\theta \mapsto V_X(\theta)$ est strictement décroissante sur $\{\theta \geq \max x_i\}$:

$$\widehat{\theta}_n = \max_{1\leq i\leq n} x_i \text{ maximise la vraisemblance.}$$

Cas 2 : $\mathcal{U}(0,\theta)$

$$\mathbb{P}(X = x) = \frac{1}{\theta+1}\mathbf{1}_{0,\theta}(x), \qquad V_X(\theta) = \frac{1}{(\theta+1)^n}\prod_{i=1}^n \mathbf{1}_{0,\theta}(x_i),$$

et $\prod_i \mathbf{1}_{0,\theta}(x_i) = 1 \iff \forall i,\ 0 \leq x_i \leq \theta \iff \max_i x_i \leq \theta$. Comme $\theta \mapsto \frac{1}{(\theta+1)^n}$ est strictement décroissante pour $\theta \geq \max x_i$:

$$\widehat{\theta}_n = \max_{1\leq i\leq n} x_i.$$

2.6 Loi binomiale négative $\mathcal{BN}(r,p)$

On a $\mathbb{P}(X = x) = \binom{x+r-1}{x} p^r(1-p)^x$ et

$$V_X(p) = \prod_{i=1}^n \binom{x_i + r - 1}{x_i} p^r(1-p)^{x_i} = \Big(\prod_{i=1}^n \binom{x_i + r - 1}{x_i}\Big) p^{rn}(1-p)^{\sum x_i}.$$

$$\ln V_X(p) = rn \ln p + \sum x_i \ln(1-p) + \sum_{i=1}^{n} \ln \binom{x_i + r - 1}{x_i}.$$

(1) Équation $\partial_\theta \ln V_X(\theta) = 0$.

$$\frac{\partial}{\partial p} \ln V_X(p) = \frac{rn}{p} - \frac{\sum x_i}{1-p} = 0 \iff (1-p)\, rn - p \sum x_i = 0 \iff rn = p\Big(rn + \sum x_i\Big) \iff p = \frac{rn}{rn + \sum x_i} = \frac{}{r +}$$

(2) Vérification de la concavité.

$$\frac{\partial^2}{\partial p^2} \ln V_X(p) = -\frac{rn}{p^2} - \frac{\sum x_i}{(1-p)^2} < 0.$$

$$\widehat{p}_n = \frac{r}{r + \overline{x}_n}.$$

On retrouve exactement l'estimateur de la méthode des moments.

2.7 Loi exponentielle $\mathcal{E}(\lambda)$

La densité est $f_\lambda(x) = \lambda e^{-\lambda x} \mathbf{1}_{\mathbb{R}_+}(x)$ et, pour tous $x_i \in \mathbb{R}_+$,

$$V_X(\lambda) = \prod_{i=1}^{n} \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum x_i}.$$

$$\ln V_X(\lambda) = \ln(\lambda^n) - \lambda \sum x_i = n \ln \lambda - \lambda \sum x_i.$$

(1) Équation $\partial_\theta \ln V_X(\theta) = 0$.

$$\frac{\partial}{\partial \lambda} \ln V_X(\lambda) = \frac{n}{\lambda} - \sum x_i = 0 \iff \lambda = \frac{n}{\sum x_i} = \frac{1}{\frac{1}{n} \sum x_i}.$$

(2) Vérification de la concavité.

$$\frac{\partial^2}{\partial \lambda^2} \ln V_X(\lambda) = -\frac{n}{\lambda^2} < 0.$$

$$\widehat{\lambda}_n = \frac{1}{\overline{x}_n}.$$

2.8 Loi normale $\mathcal{N}(\mu, \sigma^2)$

Densité $f(x) = \dfrac{1}{\sqrt{2\pi}\,\sigma} \exp\Big(- \dfrac{(x-\mu)^2}{2\sigma^2} \Big)$. La vraisemblance est

$$V_X(\mu, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\,\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = \frac{1}{(\sqrt{2\pi}\,\sigma)^n}\, e^{-\frac{\sum (x_i - \mu)^2}{2\sigma^2}}.$$

$$\ln V_X(\mu,\sigma^2) = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{\sum(x_i-\mu)^2}{2\sigma^2}.$$

(1) Équation $\partial_\theta \ln V_X(\theta) = 0$.

Dérivation par rapport à μ :

$$\frac{\partial}{\partial\mu}\ln V_X(\mu,\sigma^2) = \frac{\sum(x_i-\mu)}{\sigma^2} = 0 \iff \sum x_i = n\mu \iff \mu = \frac{\sum x_i}{n}.$$

Dérivation par rapport à σ^2, en injectant $\mu = \overline{x}_n$:

$$\frac{\partial}{\partial\sigma^2}\ln V_X(\mu,\sigma^2) = 0 \iff -\frac{n}{2}\cdot\frac{1}{\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^n (x_i-\overline{x}_n)^2 = 0 \iff \sigma^2 = \frac{1}{n}\sum_{i=1}^n (x_i-\overline{x}_n)^2.$$

(2) Vérification de la concavité.

$\dfrac{\partial^2}{\partial\mu^2}\ln V_X(\mu,\sigma^2) < 0$ et $\dfrac{\partial^2}{\partial(\sigma^2)^2}\ln V_X(\mu,\sigma^2) < 0$ aux points critiques.

$$\widehat{\mu}_n = \overline{x}_n \qquad \text{et} \qquad \widehat{\sigma}_n^2 = \frac{1}{n}\sum_{i=1}^n (x_i-\overline{x}_n)^2.$$

2.9 Loi uniforme continue $\mathcal{U}([a,b])$

Densité $f(x) = \dfrac{1}{b-a}\mathbf{1}_{[a,b]}(x)$.

Cas 1 : $\mathcal{U}([0,b])$ avec $b>0$, estimation de b

$$V_X(b) = \prod_{i=1}^n \frac{1}{b}\mathbf{1}_{[0,b]}(x_i) = \frac{1}{b^n}\prod_{i=1}^n \mathbf{1}_{[0,b]}(x_i),$$

et $\prod_i \mathbf{1}_{[0,b]}(x_i) = 1 \iff \forall i,\ 0 \le x_i \le b \iff \max_i x_i \le b$. Comme $b \mapsto \frac{1}{b^n}$ est décroissante pour $b \ge \max x_i$, le maximum est atteint en

$$\widehat{b}_n = \max_{1\le i\le n} x_i.$$

Cas 2 : $\mathcal{U}([-a,0])$ avec $-a<0$, estimation de $-a$

$$V_X(a) = \prod_{i=1}^n \frac{1}{a}\mathbf{1}_{[-a,0]}(x_i),$$

et $\prod_i \mathbf{1}_{[-a,0]}(x_i) = 1 \iff \forall i,\ -a \le x_i \le 0 \iff \forall i,\ x_i \ge -a \iff \min_i x_i \ge -a \iff -\min_i x_i \le a$. Comme $a \mapsto \frac{1}{a^n}$ est strictement décroissante pour $a \ge -\min x_i$, le maximum est atteint en

$$\widehat{a}_n = -\min_{1\le i\le n} x_i.$$

Cas 3 : $\mathcal{U}([a,b])$ avec $a < b$

$$V_X(a,b) = \prod_{i=1}^{n} \frac{1}{b-a} \mathbf{1}_{[a,b]}(x_i) = \frac{1}{(b-a)^n} \prod_{i=1}^{n} \mathbf{1}_{[a,b]}(x_i),$$

et $\prod_i \mathbf{1}_{[a,b]}(x_i) = 1 \iff \forall i,\ a \leq x_i \leq b \iff \min_i x_i \geq a$ et $\max_i x_i \leq b$. Pour rendre $(a,b) \mapsto \frac{1}{(b-a)^n}$ le plus grand possible, c'est-à-dire pour maximiser $V_X(a,b)$, il suffit de rendre $b-a$ la plus petite possible sous la contrainte $a \leq \min x_i$ et $b \geq \max x_i$. D'où

$$\widehat{a}_n = \min_{1 \leq i \leq n} x_i \qquad \text{et} \qquad \widehat{b}_n = \max_{1 \leq i \leq n} x_i.$$

3 Récapitulatif

Loi (paramètre)	**Moments**	**Max. de vraisemblance**
$\mathcal{B}(p)$	$\overline{x}_n$	$\overline{x}_n$
$\mathcal{B}(k,p)$, k connu	$\overline{x}_n/k$	$\overline{x}_n/k$
$\mathcal{P}(\lambda)$	$\overline{x}_n$	$\overline{x}_n$
$\mathcal{G}(p)$	$1/\overline{x}_n$	$1/\overline{x}_n$
$\mathcal{U}(1,\theta)$	$2\overline{x}_n - 1$	$\max x_i$
$\mathcal{BN}(r,p)$, r connu	$r/(r+\overline{x}_n)$	$r/(r+\overline{x}_n)$
$\mathcal{E}(\lambda)$	$1/\overline{x}_n$	$1/\overline{x}_n$
$\mathcal{N}(\mu,\sigma^2)$	$\overline{x}_n,\ S_n^2$	$\overline{x}_n,\ S_n^2$
$\mathcal{U}([0,b])$	$2\overline{x}_n$	$\max x_i$
$\mathcal{U}([a,b])$	$\overline{x}_n \mp \sqrt{3}\, S_n$	$\min x_i,\ \max x_i$
$\Gamma(a,b)$	$\widehat{a}_n = \overline{x}_n^2/S_n^2,\ \widehat{b}_n = \overline{x}_n/S_n^2$	(non traité)
$\mathcal{B}(a,b)$	voir cas 1, 2, 3	(non traité)